

第24章：模拟方法

□ 为什么需要Monte Carlo方法

□ Monte Carlo 方法

○ 产生独立样本

- 基本方法：概率积分变换（第一部分已讲）
- 接受—拒绝（舍选）采样
- 重要性采样

○ 产生相关样本：Markov Chain Monte Carlo


- Metropolis-Hastings算法
- Gibbs Sampler

MCMC: Markov Chain Monte Carlo

- ❑ 重要性采样和接受—拒绝采样都只 $q(x)$ 与 $\pi(x)$ 很相近似时才表现很好
- ❑ 在高维空间问题中，标准的采样方法会失败：
 - 接受—拒绝采样：维数增高时，拒绝率 $\rightarrow 100\%$
 - 重要性采样：大多数的样本权重 $\rightarrow 0$
- ❑ 对高维复杂问题，用马尔科夫链（Markov Chain）产生一些列相关样本，实现对分布的采样


MCMC

- ❑ MCMC: 一种利用一定范围内的均匀分布的随机数, 对高维空间概率进行采样的通用技术。
- ❑ 基本思想: 设计一个马尔科夫链, 使得其稳定概率为目标分布 $\pi(x)$




马尔科夫链： A Toy Example

- 假设一个孤岛上有5个家庭，他们的总财产为1。令状态表示每年的财产分布，每个家庭与其它一些家庭发生贸易，如家庭1将其收入的60%用于向家庭2购买物品...
- 问：经过一些年后，各家庭的财产情况？




马尔可夫链



$$P = \begin{pmatrix} 0.4 & 0.6 & 0.0 & 0.0 & 0.0 \\ 0.5 & 0.0 & 0.5 & 0.0 & 0.0 \\ 0.0 & 0.3 & 0.0 & 0.7 & 0.0 \\ 0.0 & 0.0 & 0.1 & 0.3 & 0.6 \\ 0.0 & 0.3 & 0.0 & 0.5 & 0.2 \end{pmatrix}$$

$$\sum_i p_{ij} = 1$$

稳定分布



$$\lim_{n \rightarrow \infty} \mu_0 P^n = \pi$$

稳定分布

year											
1	1.0	0.0	0.0	0.0	0.0		0.0	0.0	1.0	0.0	0.0
2	0.4	0.6	0.0	0.0	0.0		0.0	0.3	0.0	0.7	0.0
3	0.46	0.24	0.30	0.0	0.0		0.15	0.0	0.22	0.21	0.42
4				
5											
6	0.23	0.21	0.16	0.21	0.17		0.17	0.16	0.16	0.26	0.25
	0.17	0.20	0.13	0.28	0.21		0.17	0.20	0.13	0.28	0.21

MCMC

- 从任意的初始状态 X_0 开始，通过利用一个转换核，产生一个各态历经的链 X_t ，其稳定分布为我们感兴趣的目标分布 $\pi(x)$
 - 保证 X_t 的分布会收敛到来自分布 π 的随机变量
 - 对一个足够大的 T_0 ， X_{T_0} 可以认为是来自分布
 - 从分布 π 产生一系列相关的样本 $X_{T_0}, X_{T_0+1}, \dots$ ，可以对很多应用足够近似

MCMC

- 为了实现对目标分布的采样，设计的马尔科夫链必须具有如下性质：
 - 不可约性：可以从任意状态到达另外任意状态
 - 循环性：可以无限次访问任意状态
 - 各态历经性：忘记初始状态

- 同时，马尔科夫链的收敛速度应尽可能快

马尔科夫链的设计

- 令 $|\Omega| = r$ 表示系统的状态的数目，则
- 未知数的数目，即 P 中的元素数目为 r^2
- 约束： $2r$ 个

$$\begin{cases} \pi P = \pi \\ P \times 1 = 1 \end{cases}$$

- 所以设计满足条件马尔可夫链是一个病态问题，自由度很大。
- 细致平衡是系统平衡的充分条件。

细致平衡

- 系统总平衡（稳定分布为 π ）：

$$\sum_x \pi(x)P(x, y) = \pi(y), \forall y \in \Omega$$

$$\pi P = \pi$$

- 其中 $P(x, y)$ 表示从状态 x 到状态 y 的转移概率

$$P(x, y) = \mathbb{P}(X_{t+1} = y \mid X_t = x)$$

- 细致平衡（detail balance equation）：

$$\pi(x)P(x, y) = \pi(y)P(y, x)$$

- 如果系统细致平衡，则一定总平衡。

细致平衡

$$\pi(x)P(x, y) = \pi(y)P(y, x)$$

$$\begin{aligned}\sum_x \pi(x)P(x, y) &= \sum_x \pi(y)P(y, x) \\ &= \pi(y) \sum_x P(y, x) \\ &= \pi(y) \frac{\sum_x P(y, x)}{\sum_x P(y, x)} = 1\end{aligned}$$


Metropolis-Hastings方法

- ❑ Top 10 algorithms ! 【[top ten](#)】
- ❑ published in 1953 [Metropolis]
 - Metropolis et al. (1953), “Equation of State calculation by fast computing machines”
- ❑ Extended in 1970 [Hastings]
 - W. K. Hastings (1970), “Monte Carlo Sampling methods using Markov chain and their application”

❑ Metropolis-Hastings方法

- 基本思想：设计一个细致平衡的Markov Chain
$$\pi(x)P(x, y) = \pi(y)P(y, x)$$
- Metropolis: 建议分布对称
- Hastings: 将建议分布扩展为一般形式

MANIAC the Computer and the Man



Seated is Nick
Metropolis, the
background is
the MANIAC
vacuum tube
computer

Metropolis-Hastings方法

$$\pi(x)P(x, y) = \pi(y)P(y, x)$$

□ 细致平衡的Markov Chain

$$\left\{ \begin{array}{l} \forall y \neq x, \quad \underbrace{P(x, y)}_{\text{transition kernel}} = \underbrace{q(y | x)}_{\text{proposal}} \cdot \underbrace{\alpha(x, y)}_{\text{acceptance rate}} \\ y = x, \quad P(x, x) = 1 - \sum_{y \neq x} P(x, y) \end{array} \right.$$

$$\text{其中 } \alpha(x, y) = \min \left(1, \frac{q(x | y) \pi(y)}{q(y | x) \pi(x)} \right)$$

○ Metropolis算法中 建议分布对称, $q(x | y) = q(y | x)$, 所以

$$\alpha(x, y) = \min \left(1, \frac{\pi(y)}{\pi(x)} \right)$$

□ 转移矩阵非常稀疏, 一个状态只能到少数几个状态, 通常不保存矩阵, 而是函数形式或者是一个搜索操作

Metropolis-Hastings方法

□ Metropolis-Hastings方法满足细致平衡:

$$\begin{aligned}\pi(x)P(x, y) &= \pi(x)q(y|x)\alpha(x, y) \\ &= \pi(x)q(y|x)\min\left(1, \frac{q(x|y)\pi(y)}{q(y|x)\pi(x)}\right) \\ &= \min(\pi(x)q(y|x), \pi(y)q(x|y)) \quad (x, y \text{对称}) \\ &= \pi(y)P(y, x)\end{aligned}$$

$$\boxed{\pi(x)P(x, y) = \pi(y)P(y, x)}$$

□ 所以该马尔可夫链能收敛到目标分布 π

Metropolis-Hastings算法

- 给定在当前状态 $X_t = x$,
- 1、产生一个建议 $Y_t \sim q(y|x)$
- 2、 $X_{t+1} = \begin{cases} Y_t & \text{以概率 } \alpha(x, Y_t), \text{ 产生新样本} \\ X_t & \text{以概率 } 1 - \alpha(x, Y_t), \text{ 等待} \end{cases}$
- 其中 $\alpha(x, y) = \min\left(1, \frac{q(x|y) \pi(y)}{q(y|x) \pi(x)}\right)$
- 如果 $q(x|y)/q(y|x)$ 比例不对称, 则拒绝概率很大, 马尔科夫处于等待状态



Metropolis-Hastings算法

等价于

- 给定在当前状态 $X_t = x$,
- 1、 产生 $Y_t \sim q(y|x)$
- 2、 $U \sim Uniform[0,1]$
- 3、 $X_{t+1} = \begin{cases} Y_t & U \leq \alpha(x, Y_t) \\ X_t & \text{其它} \end{cases}$
- 其中 $\alpha(x, y) = \min\left(1, \frac{q(x|y) \pi(y)}{q(y|x) \pi(x)}\right)$

Metropolis-Hastings方法

- 建议分布 $q(y | x_t)$ 取决于当前状态 x_t
 - 可为任意固定的分布
 - 不必与 $\pi(x)$ 相似



例1：能量下降

□ 令 $\pi(x) = \frac{1}{Z} \exp[-E(x)]$, $\pi(y) = \frac{1}{Z} \exp[-E(y)]$

$$q(y|x) = q(x|y) = \text{uniform}[0,1]$$

$$\alpha(x, y) = \min \left(1, \frac{q(x|y) \pi(y)}{q(y|x) \pi(x)} \right)$$

□ 则

$$\alpha(x, y) = \min \left(1, \frac{1}{\exp[-(E(x) - E(y))]} \right) = \min(1, \exp[\Delta E])$$

$$= \begin{cases} 1 & \Delta E > 0 \\ \exp[-\Delta E] & \Delta E \leq 0 \end{cases} \quad , \text{ 能量下降, 接受}$$

□ 其中 $\Delta E = E(x) - E(y)$

Ising model (1)


- ❑ 2D网格上的 $\{-1, +1\}$ 随机变量
- ❑ 相邻变量相关

- ❑ 某个配置 x 的概率

$$\pi(x) = \frac{1}{Z} \exp\left(-\frac{E(x)}{kT}\right)$$

- ❑ 其中

- Z : 归一化常数
- $E(x)$: 能量
- T : 温度



Ising model (2)

- 例：Ising模型中 $\pi(x) = \frac{1}{Z} \exp\left(J \sum_{i \sim j} x_i x_j\right)$
 - 其中 $J = -1/kT = 0.85$
 - $x_i \sim x_j$ 为相邻像素
 - $N=256$ 为每行/列的像素数
- 则 $\sum_{i \sim j} x_i x_j = 2N(N-1) - 2d_x$
 - 其中 d_x 为边缘的数目（相邻像素分别为-1和+1）
- 所以
$$\pi(x) \propto \exp(-2Jd_x)$$

Ising model (3)

□ 用Metropolis方法采样为：

$$\pi(x) = \frac{1}{Z} \exp \left(J \sum_{i \sim j} x_i x_j \right)$$

○ 从当前配置开始：

$$x = (x_1, x_2, \dots, x_{N-1}, x_N, x_{N+1}, \dots, x_{N^2})$$

○ 随机选择一个像素，如第 N 个像素

○ 得到一个新的建议状态

$$x' = (x_1, x_2, \dots, x_{N-1}, -x_N, x_{N+1}, \dots, x_{N^2})$$

○ 则接受状态 x' 的概率为


$$\alpha(x, y) = \min \left(1, \frac{\pi(x')}{\pi(x)} \right)$$

$$= \exp \left(-2Jx_j^t (x_{j-1}^t + x_{j+1}^t) \right), \text{ for } j \neq 1 \text{ or } d$$


Ising model (4)

- 上述例子的一个结果如图所示
 - 参考代码见Ising_ Metropolis.m

随机初始状态




(a)




(b)

迭代100000次



(c)



(d)

迭代5000000次

Random walk Metropolis–Hastings

- 假设目标分布 $\pi(x)$ 定义在 d 维欧氏空间 \mathbb{R}^d 上。则对当前配置 X_t 一个自然的扰动是增加一个随机误差，即

$$Y_t = X_t + \varepsilon_t$$

- 其中 $\varepsilon_t \sim g$ ，对不同时间的 t 为IID，与 X_t 无关。
- 建议分布的形式为 $g(y - x)$ ，如果 g 对称，则该马尔科夫链为随机游走。 g 通常取球形高斯函数。
 - 若没有Metropolis–Hastings中的拒绝规则，则该马尔科夫链会漂移到无穷远，不会再回来 ($d \geq 3$)。
- 注意： x 的取值范围需为整个实数轴，否则做变换，使得换后的取值范围需为整个实数轴

Random walk Metropolis–Hastings

- 给定在当前状态 $X_t = x$,
- 1、 产生 $Y_t \sim g(y - x)$
- 2、 $X_{t+1} = \begin{cases} Y_t & \text{以概率 } \alpha(x, Y_t), \text{ 产生新样本} \\ X_t & \text{以概率 } 1 - \alpha(x, Y_t), \text{ 等待} \end{cases}$
- 其中 $\alpha(x, y) = \min\left(1, \frac{\pi(y)}{\pi(x)}\right)$

例： Random walk Metropolis–Hastings

□ 24.10例： 对下述Cauchy分布采样

$$f(x) = \frac{1}{\pi} \frac{1}{1+x^2}$$

□ 采用Random walk Metropolis–Hastings方法


- 建议分布为 $g(y-x) = N(0, b^2)$
- 所以接受率为

$$\alpha(x, y) = \min\left(1, \frac{f(y)}{f(x)}\right) = \min\left(1, \frac{1+x^2}{1+y^2}\right)$$


例： Random walk Metropolis–Hastings (续)

□ 24.10例(续)： 不同 b 对应的Metropolis链


$b=0.1$



$b=1$




$b=10$




例： Random walk Metropolis–Hastings (续)

□ 24.10例(续)： 不同 b 对应的Metropolis链得到的直方图


$b=0.1$



$b=1$



$b=10$



例3: Independence Metropolis–Hastings

- 建议分布为一个固定的分布 g
- 通常, g 应为 π 的一个近似
- 接受概率为

$$\alpha(x, y) = \min\left(1, \frac{g(y) \pi(x)}{g(x) \pi(y)}\right)$$

Gibbs sampling

- Metropolis–Hastings在高维问题中广泛使用
 - 比重要性采样和拒绝性采样表现更好
- 在很多应用中，建议通常为局部均匀移动
 - 虽然该方法在概念上和操作上都很简单，但Metropolis算法的通常不是很有效
 - 通常 $q(y | x)$ 相当窄/稀疏
 - 太宽：很多状态被拒绝，因而过程很慢
 - 太窄：随机游走(Random walk)需要很长时间才能采样整个状态空间，因而过程也很缓慢
- Gibbs sampling：对条件分布采样
 - 没有拒绝

Gibbs sampling

- ❑ 将高维采样转化为多个一维采样：对条件分布采样
- ❑ 在采样过程没有拒绝
- ❑ 对 $x \sim \pi(x) = \pi(x_1, \dots, x_d)$ 的采样通过对
$$x_i \sim \pi(X_i \mid x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_d), i = 1, \dots, d$$
- ❑ 的采样实现

Gibbs sampling

- 给定在当前状态 $x^{(t)} = (x_1^{(t)}, \dots, x_d^{(t)})$
- 1、产生 $X_1^{(t+1)} \sim \pi(X_1 | x_2^{(t)}, \dots, x_d^{(t)})$
- 2、产生 $X_2^{(t+1)} \sim \pi(X_2 | x_1^{(t)}, x_3^{(t)}, \dots, x_d^{(t)})$

...

- d 、产生 $X_d^{(t+1)} \sim \pi(X_d | x_1^{(t)}, x_2^{(t)}, \dots, x_{d-1}^{(t)})$ 形式很简单

对MRF,

$$\pi(X_i | x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_d) = \pi(X_i | x_{\setminus i}) = \pi(X_i | x_c)$$

除*i*之外的所有节点

*i*的邻居节点

Gibbs sampling

□ 最后收敛到 $\pi(x_1, \dots, x_d)$

□ $\pi \mathbf{P} = \pi$

□ 证明：用归纳法

○ 假设第 t 步满足不变方程，即 $(x_i^{(t)}, x_{[-i]}^{(t)}) \sim \pi(x_i, x_{[-i]})$

○ 那么 $x_{[-i]}^t$ 为 π 的边缘分布 $\pi(x_{[-i]}^t)$

○ 那么第 $t+1$ 步，选择第 i 个节点调整其状态
$$\pi(x_i^{t+1} | x_{[-i]}^t) \pi(x_{[-i]}^t) = \pi(x_i^{t+1}, x_{[-i]}^t)$$

○ 仍然满足分布 π

Gibbs sampling

□ Gibbs采样为Metropolis–Hastings的一个特例:

○ $x' : x_{-i}$ 固定, x_i 变化是的一个可能的取值

$$q(x' | x) = \pi(x_i | x_{-i})$$

□ 根据贝叶斯公式, 接受率为

$$\begin{aligned} \alpha &= \frac{\pi(x')}{\pi(x)} \frac{q(x | x')}{q(x' | x)} = \frac{\pi(x') \pi(x_i | x'_{-i})}{\pi(x) \pi(x'_i | x_{-i})} && \text{建议分布的定义} \\ &= \frac{\pi(x') \pi(x_i, x'_{-i}) \pi(x_{-i})}{\pi(x) \pi(x_i, x_{-i}) \pi(x'_{-i})} = \frac{\pi(x_{-i})}{\pi(x'_{-i})} = 1 && \text{条件概率的定义} \end{aligned}$$

□ 所以总是接受

Ising model

□ 例：Ising模型中 $\pi(x) = \frac{1}{Z} \exp\left(\beta \sum_{i \sim j} x_i x_j\right)$

□ 其中 $\beta = -1/kT = 0.85$

○ $x_i \sim x_j$ 为相邻像素

○ $N=256$ 为每行/列的像素数

□ 则用Gibbs采样方法采样为：

○ 对每个像素 n

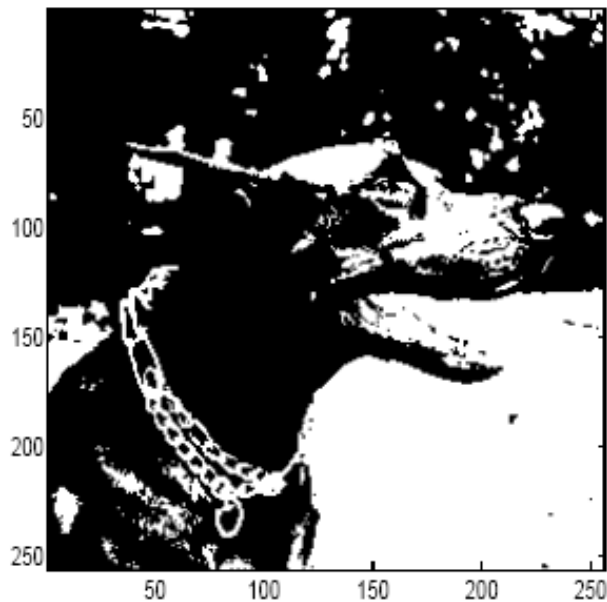
○ 根据 n 的邻居 m 邻居，计算 $w_n = \sum_{m \sim n} x_m$

○ 定义两个概率


$$p^- = \frac{\exp(-Jw_n)}{\exp(-Jw_n) + \exp(Jw_n)}, \quad p^+ = 1 - p^-$$

○ 以概率 p^- 产生 $x_n^{new} = -1$ ，以概率 p^+ 产生 $x_n^{new} = 1$

Is

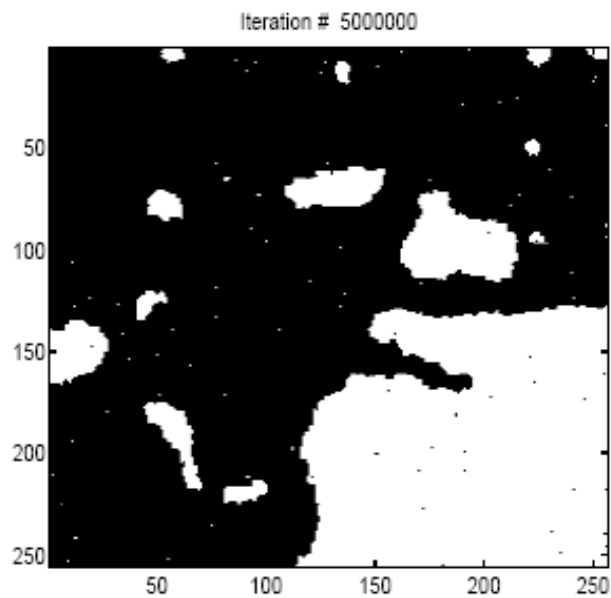


输入初始图像黑白Von Klaus




参考代码见Ising_Gibbs.m

迭代500000次



迭代5000000次




$J=0.25$, 迭代300000次

Markov blanket


- 在概率图模型（如Bayesian 网络）中，联合分布被写成一些因子的乘积
- 在给定其父亲节点的情况下，变量和其非后继节点独立
- 在给定其*Markov blanket* 的情况下，变量与其他所有节点独立
- 因此，为了对每个节点采样，我们只需对其Markov blanket取条件

$$\pi(x_i | x_{[-i]}) = \pi(x_i | MB(x_i))$$



例: Gibbs sampling

- 考虑一个简单的2个变量的贝叶斯网络



	b	-b
a	1	1
-a	1	1

- 随机初始化
- 轮流对变量进行采样

Advanced Topics

- ❑ 模拟退火：用于计算全局最优化
- ❑ Monte Carlo EM (stochastic E-step)
- ❑ 可逆跳转（Reversible jump）：用于模型选择
- ❑ Clustering
- ❑ Data-driven MCMC
- ❑ Adaptive proposal distributions
- ❑ ...

Advanced Topics

□ 怎样度量收敛性

- First hitting time, mixing time

□ 怎样诊断特定马尔科夫收敛性

- Exact sampling

参考文献

- [Jun S. Liu](#), *Monte Carlo Strategies in Scientific Computing*.
[Springer](#), 2005.
 - [www.china-pub.com](#)上有影印版，中文书名《科学计算中的蒙特卡罗策略》
- Christian P. Robert, *Monte Carlo Statistical Methods*,
Springer-Verlag, 2004.8
 - [http://www.ceremade.dauphine.fr/%7Exian/books.html](#)
- ICCV05 Course: Markov Chain Monte Carlo for Computer Vision
 - [http://civs.stat.ucla.edu/MCMC/MCMC_tutorial](#)

Reference links

□ Java MCMC applet:

○ <http://www.lbreyer.com/mcmc-webdemo.html>